

SayCan 的执行循环

1. 给定用户指令 i
2. 枚举所有技能 $\pi \in \Pi$
 - 对每个技能:
 - LLM 打分: **这个技能语义上是不是下一步?**
 - Value Function 打分: **现在能不能成功?**
3. 相乘, 选分数最高的技能
4. 执行这个技能
5. 更新环境状态
6. 把“我刚才做了什么”追加进 prompt
7. 回到第 2 步, 直到输出 `done`

$$\pi^* = \arg \max_{\pi \in \Pi} \underbrace{p(c_\pi | s, \ell_\pi)}_{\text{Affordance (能做到)}} \times \underbrace{p(\ell_\pi | i)}_{\text{LLM (该做啥)}}$$

符号解释表

| 符号 | 含义 | 机械臂场景举例 |
|--------------------------|------------------------|---------------------------------------|
| i | 用户输入的高层指令 | "把那个脏的零件挪开" |
| Π | 机器人会的所有技能集合 | {抓取, 放置, 移动到A点, ...} |
| ℓ_π | 某个技能的语言描述 | "pick up the dirty part" |
| s | 当前环境状态 (如摄像头画面) | 桌面上有3个零件, 1个脏 |
| $p(\ell_\pi i)$ | LLM: 这个技能“对不对” (语义匹配度) | LLM觉得“抓脏零件”符合指令 → 0.9 |
| $p(c_\pi s, \ell_\pi)$ | Affordance: 机器人“能不能”做到 | 脏零件在臂展内 → 0.8 |
| 最终得分 | 两者相乘 | $0.9 \times 0.8 = 0.72 \checkmark$ 选中 |

其实就是取这几个集合中的所有可行性的最大值

这个语言消歧SayCan策略, 我觉得是这样理解的

1. 用户给出最高指令
2. 遍历机器可执行动作
3. 每一个动作和最高指令的匹配评分
4. 每一个动作在当前状况下的可执行性评分
5. 两者相乘, 求取最大值, 对应的机器可执行动作, 为机器的真实执行动作

6. 执行动作之后S，即环境状态发生改变，需更改机器可执行动作的affordance评分

7. 循环该过程

机器不是创造出来动作，而是在已经设计好的这个动作之中进行选择

5 两者相乘，求取最大值，对应的机器可执行动作，为机器的真实执行动作

100% 正确，这是 SayCan 的决策核心

$$\pi^* = \arg \max_{\pi} \left(p(\ell_{\pi} | i) \times p(c_{\pi} | s, \ell_{\pi}) \right)$$

你这一步理解得非常成熟，因为你已经默认了两件事：

- ✗ 不是先语言选，再看能不能做
- ✗ 也不是先看能不能做，再想理由

好一个联合最优，好一个世界的普遍联系和永恒发展

好一个动态消歧，在执行的过程中，这个世界的状态也会不断的发生改变，也就是改变公式里面的这个S参数，世界状态，也就是这个affordance参数

arduino

Copy code

```
for step = 1,2,3,...  
    重新遍历所有可执行动作  
    重新算语言匹配  
    重新算 affordance  
    选一个  
    执行  
    更新世界状态
```

👉 状态在变，岐义会自动“坍缩”

举个工业级直觉例子

用户说：

“把那个螺丝拧紧”

- 一开始：
 - 多个螺丝 affordance 都不低
- 机器人靠近某一个后：
 - 其他螺丝 affordance ↓
 - 当前螺丝 affordance ↑

👉 不是语言理解突然变准了

👉 而是世界状态替你做了消歧

好一个歧义坍缩

⌚ 隐藏的第 6 步：执行 → 更新状态 → 重新评分

SayCan 不是一次性做完的。

真实流程是：

arduino

```
for step = 1,2,3,...  
    重新遍历所有可执行动作  
    重新算语言匹配  
    重新算 affordance  
    选一个  
    执行  
    更新世界状态
```

👉 状态在变，歧义会自动“坍缩”

在这个SayCan中这个prompt指的是一种模版，我们把它翻译成“规划上下文”

工业版 Prompt 模板 (建议你以后就用这个骨架)

[系统角色/规则]

Robot: 你是工业机械臂的“任务规划器”。

你只能从【技能列表】中选择下一步动作。

输出必须严格为： 1. <技能>，不要输出多余解释。

[少量示例] (教它“模糊→先对齐/先确认/先靠近”的套路)

Human: 把这个零件装上去。

Robot: 1. go_to(assembly_station)

Human: 把那个螺丝拧紧。

Robot: 1. align_to(screw_candidate)

[当前任务 + (可选) 历史]

Human: 把那个螺丝拧到那里。

Robot: 1.



然后你再告诉我……

果然，只要理解了这个prompt是事先写好写进这个模版的，我们就理解了这个规划上下文的本质

Prompt 是预先设计好写进系统的

一句话回答

对，Prompt 是研究员事先精心设计好的“剧本模板”，在系统运行前就写死在代码里了。

为什么 SayCan 无法处理"两个脏零件"的消歧问题?

先回顾 SayCan 的工作流程

用户指令： "把那个脏零件清理掉"



LLM 打分：哪个技能对这个指令有用？
"find dirty part" → 0.8
"pick up dirty part" → 0.7
"find clean part" → 0.1



Affordance 打分：哪个技能现在能做？
"find dirty part" → 0.9 (看到了)
"pick up dirty part" → 0.3



最终选择 = LLM分 × Affordance分



匹配技能指令，匹配可行性

SayCan策略的问题有很多，不仅仅是在这个模糊指令上面，还有的是这个skill库数据爆炸的问题

5) 技能数量扩展性：550 个技能还行，上千个怎么办？

先纠正一个数字：论文里说他们提出了 **551 个 skills** (7 个技能家族、17 个物体等)

□ Ahn 等 - 2022 - Do As I Can, Not... ; 但真正用于长时规划的，是其中更稳定、更适合组合的一部分（某些技能因为不稳定或不常用被排除）。

扩展性问题的本质是：**每一步要对候选技能逐个打分 + 逐个算 affordance (value)**，复杂度大体是 $O(|\Pi|)$ 每步。

如果上千甚至上万技能，常见解法（论文没有完整展开，但你做工业场景很实用）：

- **两阶段检索**：先用便宜的 embedding 相似度/规则把候选缩到 top-k，再让 LLM 精排 (k=20/50 这种量级)
- **层级技能库**：先选大类（导航/抓取/放置/装配），再在类内选具体技能
- **参数化技能**：减少技能离散枚举数量（把“对象/位置/姿态”变成参数槽）

你做“模糊指令语义消歧”时，这个两阶段尤其重要：先用视觉/检索把“可能的对象/动作集合”缩小，再用 LLM 做最终消歧决策。

1) 一句话定义 (最常用, 最稳)

SayCan (Ahn et al., 2022) 是一种技能级任务规划框架/方法：在给定高层自然语言指令 i 和技能集合 Π 时，它用语言模型给每个技能文本 ℓ_π 打“该不该做”的分数 $p(\ell_\pi | i)$ ，用可执行性/affordance 给“能不能做成”的分数 $p(c_\pi | s, \ell_\pi)$ ，两者相乘选择下一步技能并迭代执行直到“done”。Ahn 等 - 2022 - Do As I Can, Not...Ahn 等 - 2022 - Do As I Can, Not...

(你下次就可以说：“SayCan 框架/方法”或“SayCan 规划算法”)

2) 两句话讲创新点 (你写 related work 够用)

创新点 1：把“语言合理性”和“世界可行性”解耦：语言侧做 task-grounding（下一步是否有用），世界侧做 world-grounding（当前状态下是否能成功），并在同一概率接口中融合。Ahn 等 - 2022 - Do As I Can, Not...Ahn 等 - 2022 - Do As I Can, Not...

创新点 2：用“评分式 LLM + 严格响应结构”做技能选择：不是让 LLM 自由生成计划，而是对候选技能进行评分，并把已选技能追加到上下文里做迭代规划。Ahn 等 - 2022 - Do As I Can, Not...Ahn 等 - 2022 - Do As I Can, Not...

3) 两句话讲局限 (你写 critique/讨论部分够用)

局限 1：能力上限受限于技能库与低层技能可靠性：只有当技能足够多且足够稳定，SayCan 的长序列规划才真正有用；不稳定或不适合长任务的技能会被弃用。Ahn 等 - 2022 - Do As I Can, Not...Ahn 等 - 2022 - Do As I Can, Not...

局限 2：闭环反馈有限：在原始设定中，系统主要通过当前决策步的 value/affordance 得到环境反馈；如果技能失败或环境改变，反馈可能不足，后续工作用 inner monologue 等方式补强闭环。Ahn 等 - 2022 - Do As I Can, Not...Ahn 等 - 2022 - Do As I Can, Not...

4) “落地结果”一句话 (可选，写实验动机时用)

作者在真实厨房验证了从 mock 到 real 的迁移：规划成功率下降约 3%，执行成功率下降约 14%，显示底层策略与 value/affordance 具有一定泛化能力。Ahn 等 - 2022 - Do As I Can, Not...

5) 你课题专用版本 (工业机械臂 + 模糊指令语义消歧)

如果你要把 SayCan 这套话术改成“你的论文会用的版本”，我建议这样写：

我们借鉴 SayCan 的技能级规划思想，将模糊高层指令转化为“候选技能集合上的排序问题”：语言侧提供“语义上更像下一步”的评分，世界侧用工业约束/可达性/碰撞/对准成功率等构造“可执行性评分”，两者融合选择下一步动作并迭代更新，从而在执行过程中逐步消歧。（对应 SayCan 的 $p(\ell_\pi | i) \times p(c_\pi | s, \ell_\pi)$ 结构）Ahn 等 - 2022 - Do As I Can, Not...

确实，LLM模型就是用来做这个推理的，那么不同的LLM模型在推理上面的不同体现着他们之间的优劣

接下来阅读inner monologue论文