OpenVLA开源项目的跑通记录

一个生活比喻

你可以把操作系统想象成"厨房"：**Windows** 是精装修的品牌厨房，好看易用，但布局固定，改造困难。**Linux** 是毛坯厨房，给你全套工具和图纸，你可以随意改造成任何样子。

对于普通用户，精装修更省心；对于开发者和研究者，毛坯房的自由度更高。

为什么开发者经常使用这个linux

WSL2 的本质

回到你要做的事情：WSL2 相当于在你 Windows 电脑的"身体"里，**额外装了一个 Linux 灵魂**，让它们共存。两个"灵魂"共享同一套硬件（CPU、显卡、内存），但各自有独立的文件系统和运行环境。

卧槽这个东西，真是精彩至极啊

本地小规模验证，目的是，输入文本加图像，输出这个action序列

结构

```
Windows 11（主系统）
    └── WSL 2（微软的Linux兼容技术）
            └── Ubuntu 22.04（你选择的Linux发行版）
                    └── Conda 环境（openvla_wsl）
                            └── OpenVLA 项目
```

生活比喻

GitHub = 代码的共享平台（存放代码）

HuggingFace = 模型的共享平台（存放训练好的"大脑"）

就像你去 GitHub 下载别人写好的代码一样，你去 HuggingFace 下载别人训练好的模型

可以AI界的github

在做量化减少这个开销的时候，系统的自动调度（accelerate硬件分配），和这个.to(device)的矛盾

这个错误困扰了我一个小时

收到：你现在**只差把 `/act` 的真实输入 JSON 搞清楚并成功打一次请求拿到动作输出**，就完成 OpenVLA baseline 闭环。下面我直接把"最后一公里"按**最小闭环 3 条命令**给你（不需要猜 schema）。

---

1) 一条命令：从 OpenAPI 反推 `/act` 的真实 Request body（最快、最准）

在 **WSL 里**跑：

bash Copy code

```
curl -s http://localhost:8000/openapi.json | python -m json.tool | sed -n '/"\/act"/,/^    }/p'
```

你重点看这几块（在输出里搜索）：

- `"requestBody"` 下面的 `"schema"` / `"properties"`：**会列出所有字段名**
- 以及 `"required"`：**哪些是必填**
- `"content"`：看是 `application/json` 还是 `multipart/form-data`

> 如果这里能看到字段名，那就**完全不需要进代码**，直接进入第 3 步发请求。

这个act，相当于一个项目说明书，规范着我们实际的运行

```
python - <<'PY'
import requests, numpy as np
from PIL import Image

img_path = "/mnt/d/02614db1fa77ac2655db5be6048dc599.jpg" # 换成你的图片路径
img = np.array(Image.open(img_path).convert("RGB"), dtype=np.uint8)

payload = {
    "instruction": "pick up the red screw",
    "image": img.tolist(),   # 关键：用 JSON 能传的 list
}

r = requests.post("http://localhost:8000/act", json=payload, timeout=120)
print("status:", r.status_code)
print("text:", r.text[:500])
print(r.headers)
print("server:", r.headers.get("server"))

PY

```

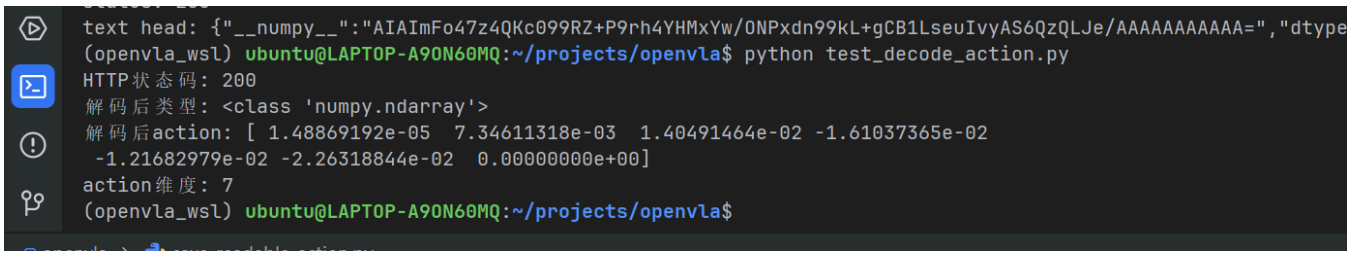

太难了，这个结果出来真不容易，我决定稍后学习当下最先进的工具，掌握一整套开发流程

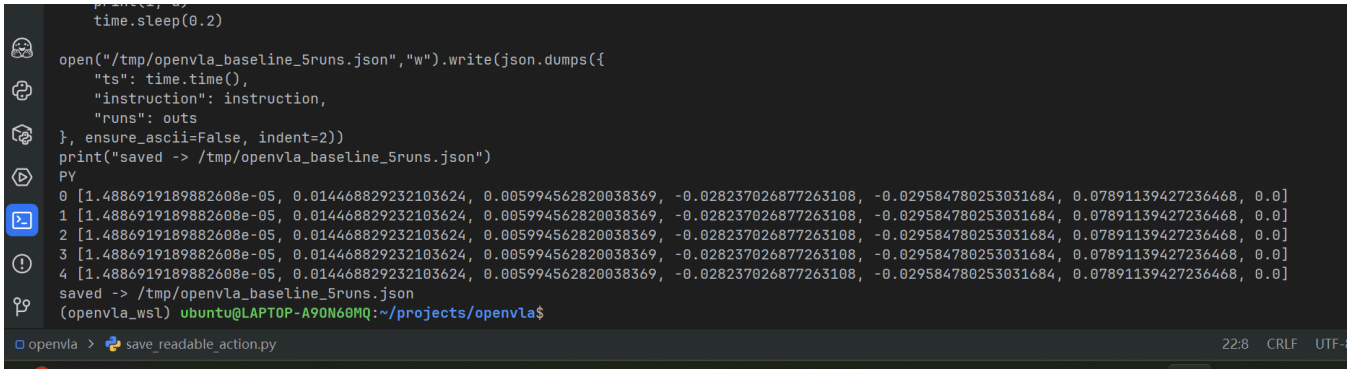

终于出结果了

不同模糊程度的实验结果的对比

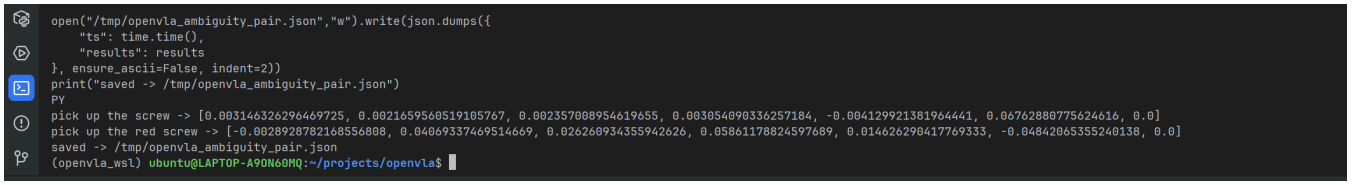

目前完成的任务

你到目前为止完成的任务	你产出的“可交付物”	这件事在科研里叫什么	你现在立刻能做什么（基于它）	对你“模糊指令消歧”课题的意义
把 OpenVLA 服务**跑通**（/act 稳定返回 7 维 action，可解码）	`/act` 可用的推理服务 + action_7d 可读解析（delta_xyz / delta_rot / gripper）	**Baseline 推理闭环**（能跑、能输出）	给任意图+指令，稳定拿到 action，并把 action 写成“人类可读”的格式	你有了“机器人动作输出”的统一接口，后面消歧策略只需要改变输入文本/流程
做“同图同指令重复多次”验证稳定性（repeats）	输出里带 latency、重复结果（N 次 action）	**稳定性验证**（repeatability check）	衡量同一输入多次输出是否一致，粗看模型是否抖动	消歧实验必须先保证“模型不乱抖”，否则你分不清是消歧有效还是模型随机性
做“模糊 vs 明确”对照实验，并落盘成标准 JSON	`outputs/pair_scene_01.json`（meta + results）	**最小对照实验**（controlled comparison）	同一张图，换两种指令，得到两组动作输出并保存，可复现	这是“模糊指令”研究的最小实验单元：你已经能观察“语言变清楚 → 动作如何变化”
把零散命令整理成脚本（run_pair / run_suite）	`run_pair.py`、`run_suite.py`	**实验脚本化**（reproducible runner）	一条命令跑一对/一批测试样例，自动保存结果	你后面每次改消歧策略，都能用同一套脚本重复跑、对比结果
固定最小评测集配置（suite.json）	`data/suite.json`（图像路径 + prompts + repeats 等）	**最小评测集**（mini benchmark）	快速扩展到 10–30 张图、20–50 条指令的固定测试集	这是科研最关键的“对照公平性”：同一套输入才能比较不同消歧方法

你到目前为止完成的任务	你产出的“可交付物”	这件事在科研里叫什么	你现在立刻能做什么（基于它）	对你“模糊指令消歧”课题的意义
加入最小量化指标（L2/稳定性等）并输出 CSV	`metrics.py` + `metrics.csv`（或 results.csv）	**量化评估**（quantitative evaluation）	自动出表：模糊 vs 明确的 L2(action)、最大差异维度、稳定性	你已经能写“实验结果表格”，不是口头描述；为论文实验章节打底
一键化运行（Makefile pipeline）	`Makefile`（serve/run_suite/metrics/pipeline）	**可复现流水线**（one-command pipeline）	新机器/新同学照着 `make pipeline` 复现整套结果	复现从“个人工程”变成“团队可复用资产”，后续迭代省很多时间
写清楚复现流程（README）	`README.md`（Quick Reproduction）	**复现报告雏形**（deliverable reproduction）	别人 clone 仓库，2–3 条命令拿到同样格式输出	你已经具备“可以交付”的 baseline，后面做消歧就是在这个底座上叠加方法

1. L2 (L2 Norm / Euclidean Distance) —— “差异度打分器”

在你的代码里，`L2` 指的是 **L2 范数（欧几里得距离）**。

- **通俗理解：** 它是用来衡量**“两个动作之间到底差了多少”**的一把尺子。
- **在 OpenVLA 里的作用：** 你之前的实验里，让机器人针对“拿螺丝”（模糊指令）和“拿红螺丝”（清晰指令）分别输出了两个 **7维向量**（那 7 个数字）。
  - 如果不算 L2，你很难肉眼看出 `[0.1, 0.2...]` 和 `[0.11, 0.19...]` 到底有多大区别。
  - **L2 就是把这 7 个数字的差异算成一个总分。**
  - **公式：** $\sqrt{(x_1-y_1)^2+(x_2-y_2)^2+\dots}$

怎么看结果？

- **L2 很大：** 说明机器人认为“拿螺丝”和“拿红螺丝”是**完全不同**的两件事（动作差异大）。
- **L2 很小（接近 0）：** 说明机器人觉得这两句话没啥区别，动作基本一致。

在你截图 `image_b5ab1e.png` 第 176 行： `row['l2_mean_amb_vs_clear']` 这就是在计算：**“模糊指令下的动作” VS “清晰指令下的动作” 到底有多大的距离。** 这是验证你

总体上的差异度打分器

这个脚本可以当做记录实验结果的表格

总结：你的 `metrics.py` 在干嘛？

这个脚本的工作流是：

1. **读取 JSON：** 拿到你之前保存的那些“7维动作向量”。
2. **计算 L2：** 算出向量之间的**差异距离**（看看机器人是不是真的听懂了指令的区别）。
3. **写入 CSV：** 把算出来的分数保存成**表格文件**，作为你的最终实验结论。

关于项目部分代码的理解

这段代码本质上是在做一件很“工程但关键”的事：把你的任务指令（instruction）包装成 LLM 最熟悉的“聊天对话格式”，让它更容易稳定地产生“动作 token”。你可以把它理解成：给大模型写一张标准化的“提问卡片”。

这一点和规划上下文不谋而合

```
---
4. 构建Prompt

prompt_builder = self.get_prompt_builder()
prompt_builder.add_turn(role="human", message=f"What action should the robot take to {instruction.lower()}?")
prompt_text = prompt_builder.get_prompt()

解释：将用户指令包装成对话格式。例如：
USER: What action should the robot take to pick up the red block?
ASSISTANT:
这样LLM就会"回答"动作token。
```

- 往对话里加一轮：**人类说的话**（role="human"）。
- message 是一个固定问句模板：
  - “机器人应该采取什么动作来完成 {你的指令}？”
- `instruction.lower()`：把指令转成小写，属于“文本归一化（normalization）”
  - 目的：减少大小写差异带来的无谓变化，让模型输入更一致（比如 “Pick up…” 和 “pick up…”）。

python Copy code

```
prompt_text = prompt_builder.get_prompt()
```

- 把当前累计的对话轮次，**拼成最终的 prompt 字符串。**
- 这个字符串后面会被 tokenizer 变成 `input_ids`，送进模型。

有意思，文本对话，最终才进行这个执行

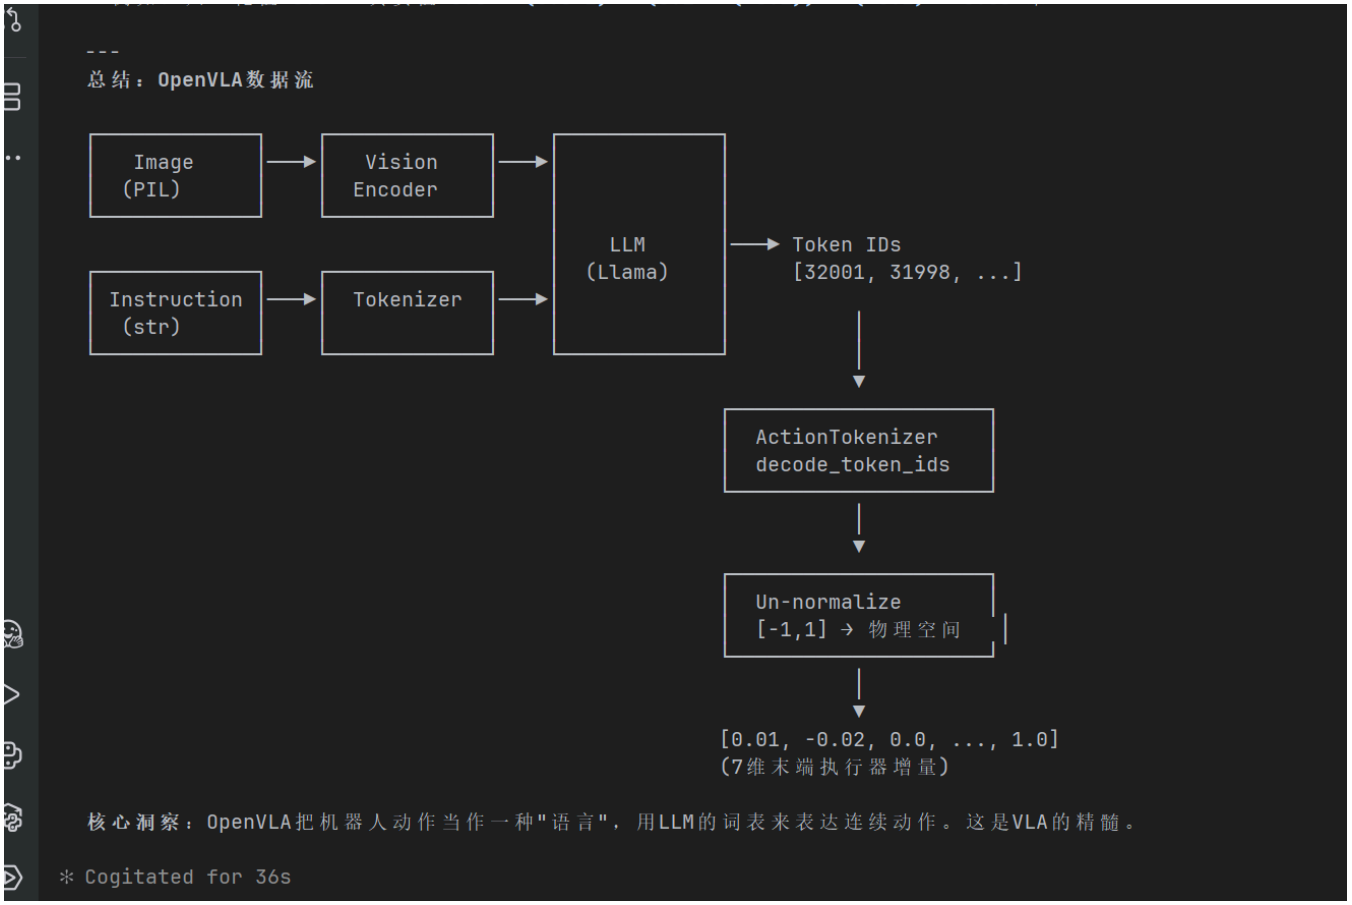

直接在项目里给我讲解，这个claude code skill真是强大

读了这么多，你应该能够感觉到这个东西的合理性

```
self.action_token_begin_idx: int = int(self.tokenizer.vocab_size - (self.n_bins + 1))
```

这个冒号是这个类型注解的意思，表示的是这个前面这个东西是这个int类型，可以触发这个静态编译

非常符合工程直觉，并且很多东西都是一个意义的赋予，而不是这个本来的原貌

因为模型不能直接理解字符串，它只能处理数字。

---

2) 什么叫 token id？（中文：词元编号 / token 的索引）

token id 就是：

> “每一个 token 在词表（vocabulary）里的编号（ID）”。

你可以把它类比成：

- 词表 = 一本字典
- token = 字典里的某个词条
- token id = 这个词条在字典里的“页码/编号”

比如（举例，不代表真实 LLaMA）：

- `"robot"` → id 1234
- `"pick"` → id 5678
- `"up"` → id 910

模型吃进去的不是 `"robot pick up"`，而是 `[1234, 5678, 910]` 这串数字。

好一个词元编号，真是一个精彩至极的设计，所以我们是对这个tokenid进行解码

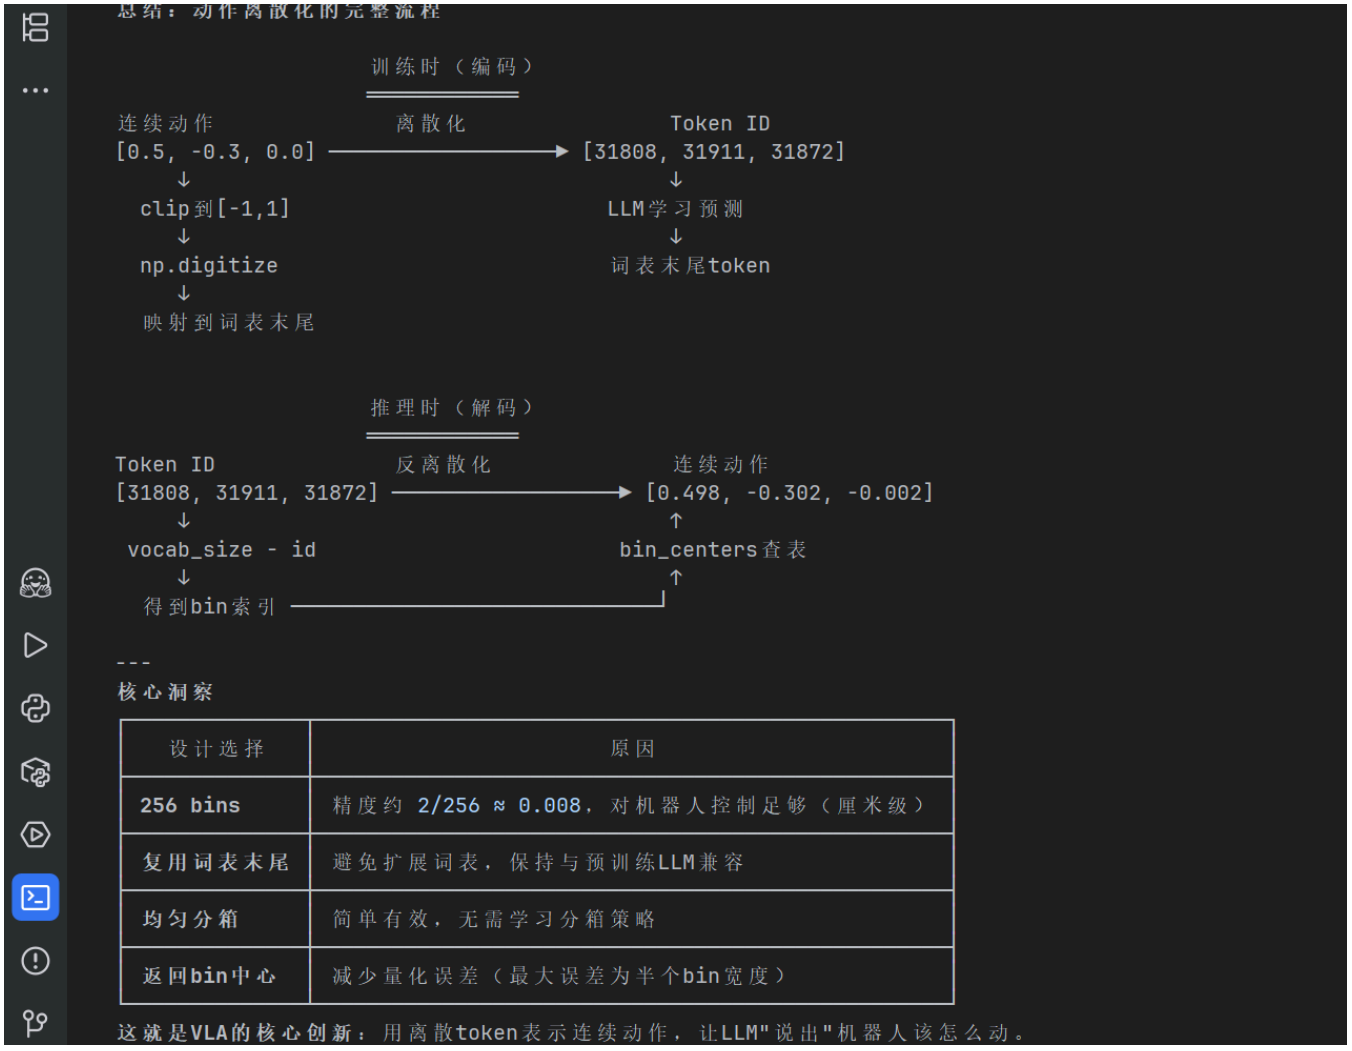

到这个tokenid进行这个学习预测，到这个-1-1的归一化进行这个输出具体连续的动作序列

---

2) Projector（MLP Adapter）：负责"对齐维度/对齐表征"，让视觉特征能喂给 LLM

它做什么?

Vision Backbone输出的向量维度是 `Dv`，但 LLaMA 期望的 token 向量维度是 `Dh`（LLaMA hidden size）。
Projector 就是一个 MLP（多层感知机）把：

$$\mathbb{R}^{Dv} \rightarrow \mathbb{R}^{Dh}$$

每个视觉 token 都做一次这样的映射。

你可以把它理解成：

- 视觉模型说的是"视觉方言"（维度、分布、语义空间都不同）

好一个对奇维度，对奇表征，充当了一个翻译官的作用

两个有着不同强项的目标检测

DINO 像“做视觉表征底座”，希望每一块都学得细；

SigLIP 像“做语义对齐”，希望整图语义对齐文本更稳。

在 OpenVLA 这种结构里

如果视觉 backbone 是 “DinoSigLIP” 这种组合/融合，通常也是想要：

- **DINO 提供更强的空间结构与局部可用性**
- **SigLIP 提供更强的语义对齐能力（尤其与语言 token 对齐）**

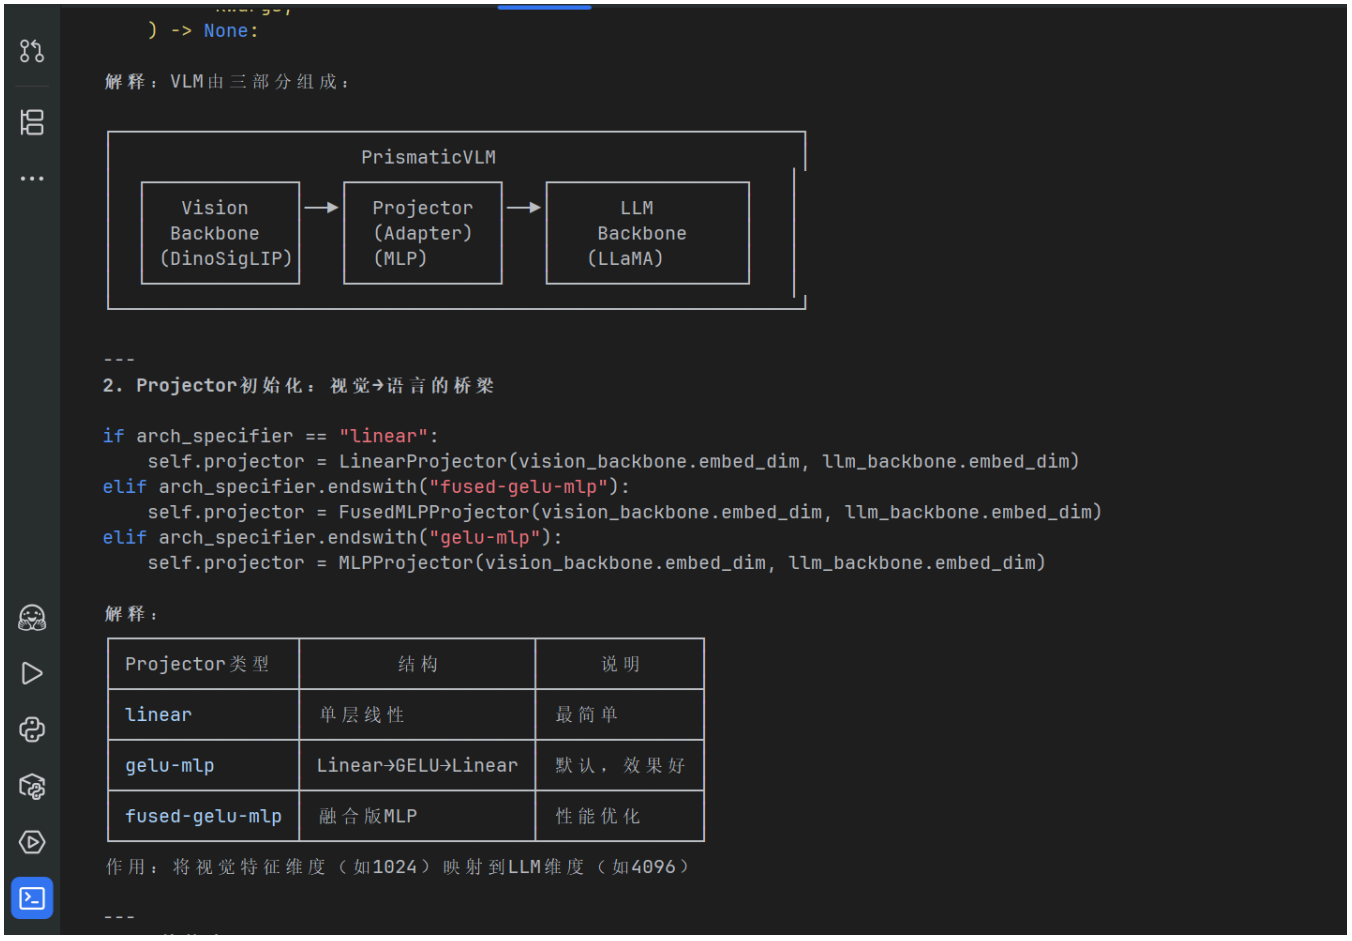

从1024维度，到这个4096维度，这个多层感知机解决这个维度和其他的东西不匹配的问题

3. 训练策略：freeze_backbones（重要）

```python
def freeze_backbones(self, stage: str) -> None:
    if stage == "align":
        self.vision_backbone.requires_grad_(False)    # 冻结
        self.llm_backbone.requires_grad_(False)       # 冻结
        self.projector.requires_grad_(True)           # 只训练Projector

    elif stage in {"finetune", "vla-train"}:
        self.vision_backbone.requires_grad_(False)    # 冻结
        self.llm_backbone.requires_grad_(True)        # 训练
        self.projector.requires_grad_(True)           # 训练

    elif stage in {"full-finetune", "vla-full-train"}:
        self.vision_backbone.requires_grad_(True)     # 全部训练
        self.llm_backbone.requires_grad_(True)
        self.projector.requires_grad_(True)
```

解释：VLM的两阶段训练策略（来自LLaVA）：

阶段	Vision	Projector	LLM	目的
align	❄️冻结	🔥训练	❄️冻结	对齐视觉-语言表征
finetune	❄️冻结	🔥训练	🔥训练	学习任务能力
full-finetune	🔥训练	🔥训练	🔥训练	端到端微调

---

4. 核心前向传播 forward（最重要）

4.1 视觉特征提取

有意思，这个冻结体现在这个维度的关闭的部分false部分

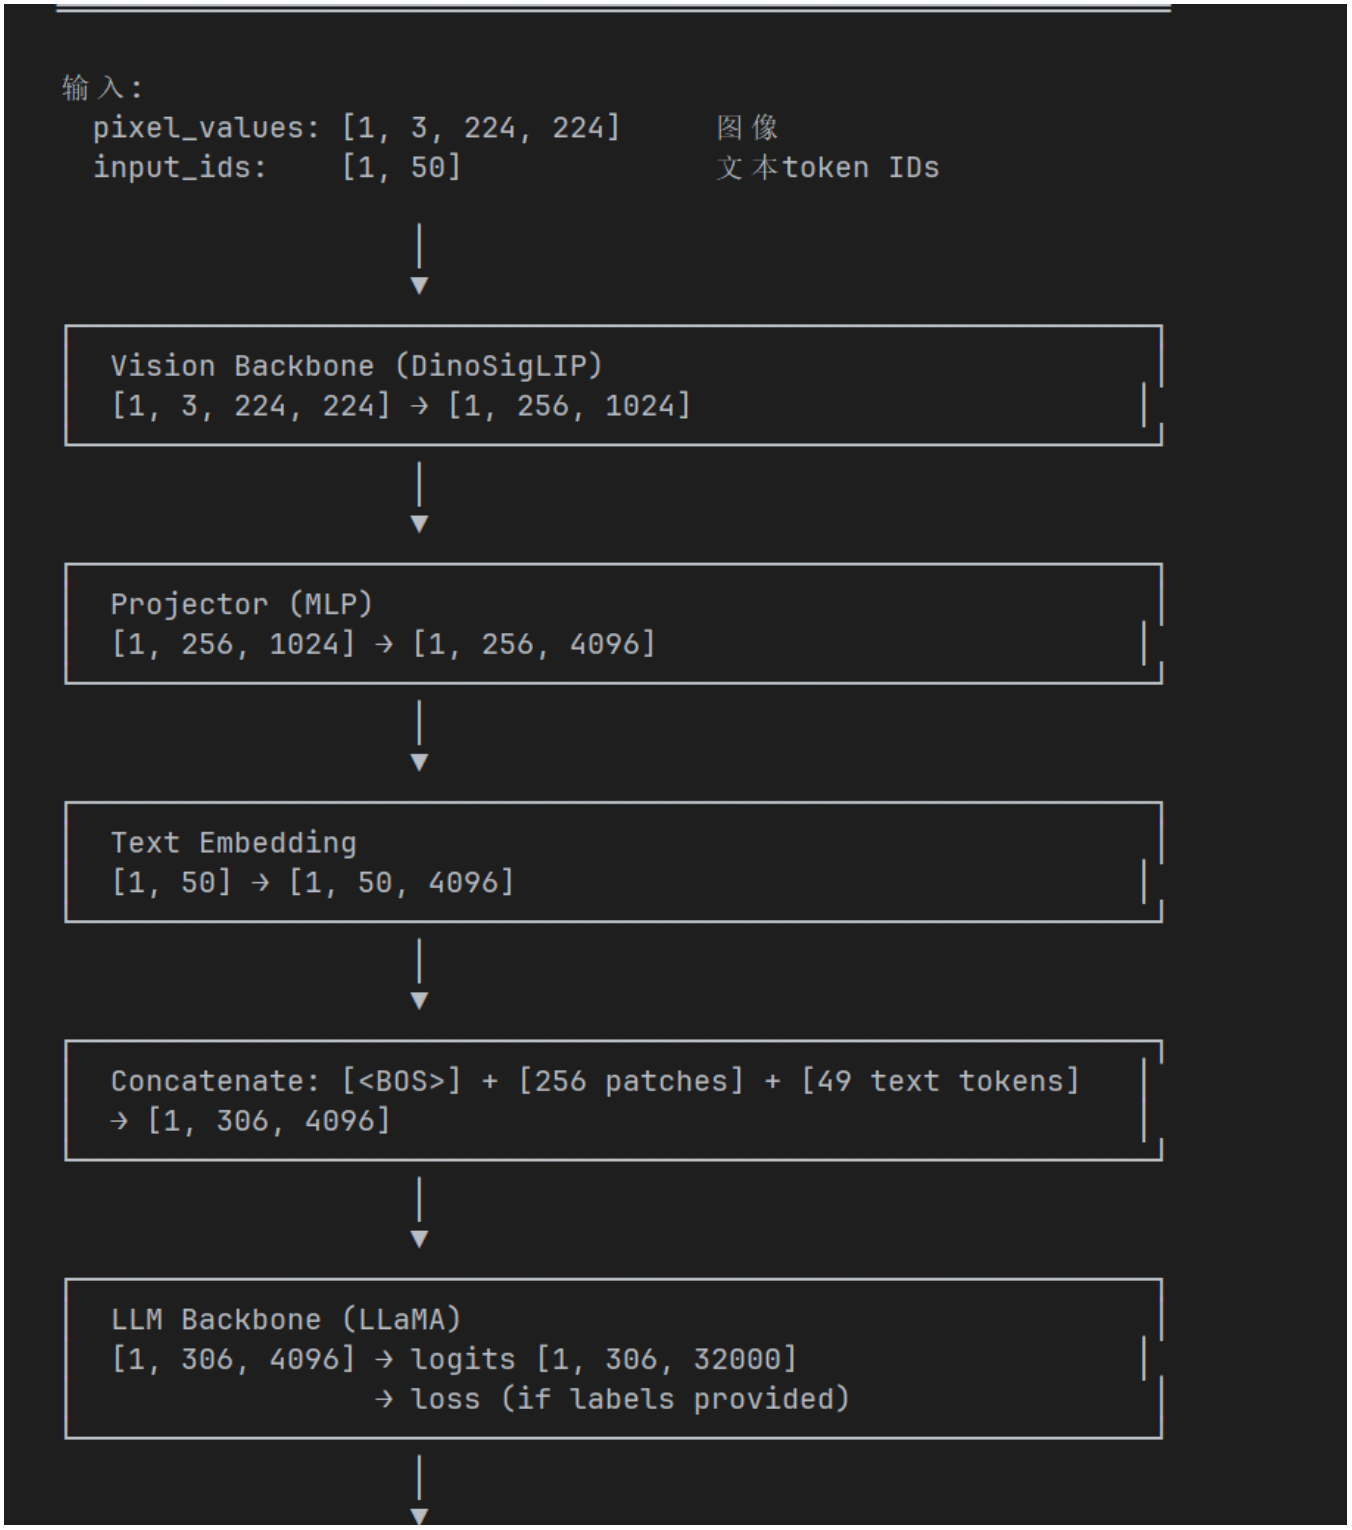

这就是数据格式不断的转换吗，真是精彩

图像需要进行两次转换，一次是特征提取，一次是维度或者说格式对齐

文本只需要进行一次这个文本嵌入，相当于是图片的第二步骤

第三步骤，进行这个文本和这个图片相同格式的对齐，发给这个LLM大脑，推理出这个动作，可以在这个地方建立损失函数进行降低损失，反向传播，进行数据优化

然后最终结果进行解码为动作，记录数据

核心洞察机制

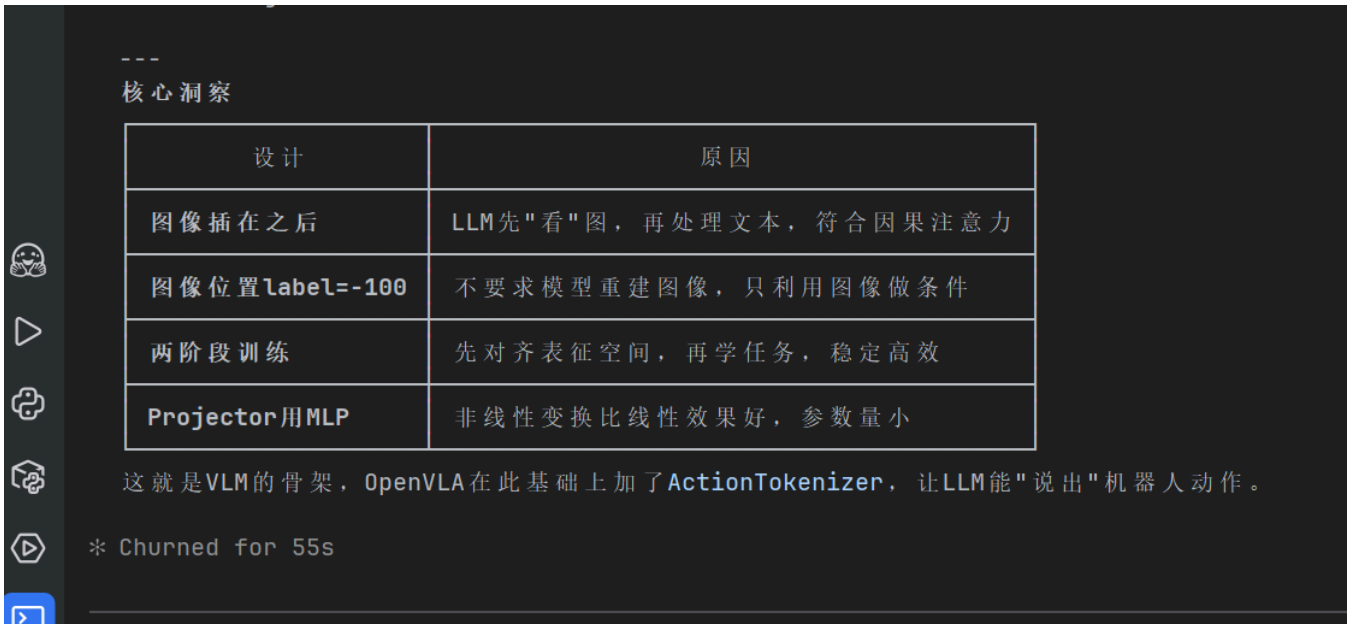

核心洞察

设计	原因
图像插在之后	LLM先"看"图，再处理文本，符合因果注意力
图像位置label=-100	不要求模型重建图像，只利用图像做条件
两阶段训练	先对齐表征空间，再学任务，稳定高效
Projector用MLP	非线性变换比线性效果好，参数量小

这就是VLM的骨架，OpenVLA在此基础上加了ActionTokenizer，让LLM能"说出"机器人动作。

✻ Churned for 55s

● deploy.py 关键要点

1. 核心架构

- C/S架构：FastAPI服务器 + REST API（/act端点）
- 输入：{"image": np.ndarray, "instruction": str}
- 输出：{"action": np.ndarray}（7维机器人动作）

2. 模型加载策略（显存优化关键）

```
BitsAndBytesConfig(
    load_in_4bit=True,           # 4-bit量化
    bnb_4bit_quant_type="nf4",   # NormalFloat4量化
    bnb_4bit_compute_dtype=torch.float16
)
device_map="auto"                # 自动CPU/GPU分配
max_memory={0: "5GiB", "cpu": "32GiB"}  # 显存不足时offload到CPU
```

这个C\S架构还是非常有意思的

- **扣分（Loss）：** **0.105** (非常低，几乎满分)

学生 2：学渣（犹豫不决，蒙对了）

- **回答：** 呃... A 的概率是 **0.3**，B 是 0.3，C 是 0.4...（虽然 A 概率不高，但它是正确答案里最高的，所以算蒙对了）。
- **老师（交叉熵）评价：** 虽然你选了 A，但你心里没底啊。你需要更坚定一点！
- **扣分（Loss）：** **1.20** (扣分中等，惩罚它的不自信)

学生 3：捣乱分子（自信地选错了）

- **回答：** 我敢打赌！A 的概率只有 **0.01**，D 的概率是 0.99！
- **老师（交叉熵）评价：** 你不仅错了，还错得这么离谱！我要狠狠罚你！
- **扣分（Loss）：** **4.60** (扣分极其巨大！)

核心直觉： 交叉熵不仅仅看你"选没选对"，它更看重**"你对正确答案的预测概率有多高"**。

- 你对正确答案预测的概率越**接近 1**，交叉熵（Loss）就越**接近 0**。
- 你对正确答案预测的概率越**接近 0**，交叉熵（Loss）就会**爆炸式增长**（趋向无穷大）。

交叉熵，好一个对正确的预测概率有多高，这也是损失函数的一种，越低意味着预测的越稳定和精准

---

1. 分布式 (Distributed) —— FSDP 分片

截图里写着：`FSDP分片，支持64+ GPU跨节点训练`。

- **这是什么？**
  - **背景：** OpenVLA 是一个 7B（70亿参数）的巨型模型。如果想要**全量训练**它，显存需求大得惊人，单张甚至单台服务器（8张显卡）都装不下。
  - **FSDP (Fully Sharded Data Parallel)：** 这是一种"化整为零"的技术。它不让一张显卡死记硬背整个模型，而是把模型**切成几十份（分片/Sharding）**。
  - **怎么工作：** 比如有 64 张显卡，每张卡只存 1/64 的模型参数。当需要计算时，显卡之间疯狂交换数据，拼凑出临时的完整参数。

好一个分布式，真是符合我们的日常策略直觉

Open X-Embodiment Dataset（开放 X-具身智能数据集）。

openvla正是因为吃了这么多数据集，才能表现出如此强大的泛化能力