



VLA综述论文精读笔记

论文标题: A Survey on Vision-Language-Action Models for Embodied AI

作者: Yueen Ma, Zixing Song, Yuzheng Zhuang, Jianye Hao, Irwin King

阅读日期: 2025年1月

阅读目的: 为"工业机械臂模糊指令语义消歧"课题建立理论基础

1 一句话总结

VLA是一类能够接收视觉和语言输入、输出机器人动作的多模态模型，其核心架构分为高层任务规划器（理解指令、分解任务）和低层控制策略（执行具体动作），而语言指令的理解与落地（Grounding）是连接两者的关键桥梁。

2 核心分类体系

VLA的三大研究主线

- 1 VLA Models
- 2 | — 🧩 Components (组件研究)
- 3 | | — 强化学习: DQN → PPO → Decision Transformer
- 4 | | — 预训练视觉表征: CLIP, R3M, MVP, VC-1
- 5 | | — 世界模型: Dreamer, Genie, TWM
- 6 | | — 推理能力: Embodied Chain-of-Thought
- 7 |
- 8 | — 🎮 Control Policy (低层控制策略)
- 9 | | — 非Transformer: CLIPort, BC-Z, MCIL
- 10 | | — Transformer-based: RT-1, Gato, RoboCat
- 11 | | — 多模态指令: VIMA, MOO 🔄 【技术相关】
- 12 | | — 3D视觉: PerAct, Act3D, RVT
- 13 | | — 扩散策略: Diffusion Policy, DP3
- 14 | | — 大型VLA: RT-2, OpenVLA
- 15 |
- 16 | — 📅 Task Planner (高层任务规划)
- 17 | | — 端到端: PaLM-E
- 18 | | — 模块化
- 19 | | | — 语言驱动: SayCan, Inner Monologue 🔄 【核心相关】
- 20 | | | — 代码驱动: ProgPrompt, ChatGPT for Robotics
- 21 | | | — Grounded (落地) 🔄 【直接相关】
- 22 | | | | — Task Grounding (任务落地)
- 23 | | | | — World Grounding (世界落地/Affordance)



我的课题在哪里？

"工业机械臂模糊指令语义消歧" 位于：

- Task Planner → Modular → Language-based 分支
- 核心挑战：当用户说"把那个螺丝拧到那里"时，如何消解"那个"和"那里"的歧义

3 与我课题的关系

直接相关的概念

概念	论文中的位置	与我课题的联系
Grounding	§IV-A3, Figure 6	把模糊的语言落地到具体物体/位置
Language-conditioned Policy	§III-B, Table III	指令如何影响动作生成
Task Decomposition	§IV-B1	模糊指令需要先分解再执行
Affordance	§III-A, SayCan	判断"能不能做"来消歧
Multimodal Prompts	§III-B3, VIMA	用多模态信息辅助消歧

关键发现

- 1. SayCan的"task-grounding + world-grounding"框架
 - Task grounding: LLM说"应该做什么"
 - World grounding: Affordance判断"能不能做"
 - 启发: 模糊指令消歧可以用类似的双重验证机制
- 2. Inner Monologue的闭环反馈
 - 执行过程中不断获取反馈，动态调整理解
 - 启发: 消歧不一定是一次性的，可以在执行中逐步确认
- 3. VIMA的多模态指令
 - 除了语言，还可以用图像、演示等方式指定目标
 - 启发: 当语言模糊时，可以请求用户提供更多模态的信息

4 待读论文清单

☆☆☆ 必读（与课题直接相关）

#	论文	原因	预计耗时
1	SayCan (2022)	Grounding LLM的开创性工作	3小时
2	Inner Monologue (2022)	语言反馈闭环控制	2小时
3	CLIP (2021)	视觉-语言对齐的基础	3小时

★★ 推荐阅读（技术基础）

#	论文	原因	预计耗时
4	RT-2 (2023)	理解Large VLA	2小时
5	VIMA (2022)	多模态指令处理	2小时
6	OpenVLA (2024)	开源可实验	2小时

★ 扩展阅读（深入理解）

#	论文	原因
7	Grounding DINO	Visual Grounding的SOTA
8	LLM-Planner	LLM做任务规划
9	ProgPrompt	代码驱动的任务规划

5 我的疑问

概念层面

- 1. **Grounding vs Disambiguation:** 这两个概念的边界在哪里？Grounding是消歧的一种手段，还是消歧是Grounding的前置步骤？
- 2. **Affordance的计算:** SayCan用value function作为affordance，但在工业场景中，如何定义和计算affordance？

技术层面

- 3. **FiLM vs Cross-Attention:** 两种语言-视觉融合方式各有什么优缺点？在消歧任务中哪个更合适？
- 4. **Action Chunking:** ACT论文提出的action chunking对连续动作很有效，但对于需要精确消歧的任务，会不会因为"打包预测"而丢失细节？

实验层面

- 5. **数据集缺口:** 现有数据集（RefCOCO, CALVIN等）的指令都比较清晰，有没有专门针对模糊指令的benchmark？如果没有，我是否需要自己构建？
- 6. **评估指标:** 如何评估"消歧"的效果？除了最终任务成功率，有没有更细粒度的指标？

6 关键图表索引

图表	页码	内容	重要性
Figure 2a	p.2	VLA概念韦恩图	★★★

图表	页码	内容	重要性
Figure 2b	p.2	发展时间线	☆☆
Figure 3	p.3	完整分类体系	☆☆☆
Figure 4	p.7	层级架构示意	☆☆☆
Figure 5	p.9	5种VLA架构	☆☆☆
Figure 6	p.13	模块化Task Planner	☆☆☆
Table III	p.8	控制策略对比表	☆☆
Table V	p.14	数据集汇总	☆☆

7 术语表（方便复习）

术语	中文	解释
VLA	视觉-语言-动作模型	接收视觉和语言，输出动作
Grounding	落地/接地	把抽象语言对应到具体物体/位置
Affordance	可供性	物体"能被怎么用"的属性
FiLM	特征调制层	用语言调制视觉特征的方法
BC	行为克隆	直接模仿专家动作的学习方式
DDPM	去噪扩散概率模型	生成式模型，用于动作生成
Task Planner	任务规划器	把长期目标分解为子任务
Control Policy	控制策略	执行具体动作的策略网络

笔记完成时间: 2025年1月