

融汇贯通，系统回顾

3) 它怎么训练的（你会 PyTorch，就看这个逻辑）

CLIP 有两个编码器：

- 图像编码器 $f_\theta(\text{image})$ （比如 ResNet / ViT）
- 文本编码器 $g_\phi(\text{text})$ （比如 Transformer）

得到向量后做相似度（通常是余弦相似度）：

$$s_{ij} = \frac{f(x_i) \cdot g(t_j)}{\|f(x_i)\| \|g(t_j)\|}$$

训练目标（对比学习的核心）：

在一个 batch 里，图片 x_i 应该最像它对应的文字 t_i ，而不是别人的 t_j 。

原来如此，这个是训练的过程，训练的过程就是让这个正确的语句和正确的内容进行对齐

你看出来了吗？训练时它学的不是“动作本身”，而是“怎么把噪声去掉”。
但反过来，推理时不断去噪，就得到了动作。

最后一句“哲学设计思想”

Diffusion Policy 的哲学很像：

不要强迫模型一次就给出“唯一正确”的动作；
让它从不确定开始，通过迭代逐步逼近可执行的方案。

这跟你做“模糊指令消歧”其实是同一类思想：先承认不确定，再通过交互/推理把不确定收敛掉。

人的思想特点，去伪存真

同时也体现了一个思想特点，那就是，先做起来，然后不断的更正，再达到完美的结果

5) 给你一个超级直观的类比

- 训练：老师给你“被涂乱的正确答案”，让你学会“怎么擦掉涂鸦”。
 - 推理：考试时你只有一张“全是涂鸦的空白纸”，你得**自己一遍遍擦**，直到擦出一份合理答案。
 - 打分：是你把两份答案拿去给另一个老师判卷（可选步骤）。
-

监督学习的训练过程

3) 为什么要监督噪声？而不是直接监督动作？

直觉上：**监督噪声更容易学出“生成整个动作分布”的能力。**

因为机器人动作常常是**多解的**（multi-modal，多峰）：

- 同一个物体可以从左抓、从右抓都行
- 放置也可以有好几条轨迹都安全

如果你直接回归动作 a ，模型容易学成“平均动作”，反而不合理（比如左右抓法平均后变成从中间撞上去）。

而 diffusion 用“去噪生成”的方式，更像是在学：

哪些动作序列是“高概率/合理”的区域，然后从中采样一个。

好一个生成这个平均动作，那么我们这个就是预测噪声就可以避免这个问题

4) 它和“自监督/无监督”有什么关系？

Diffusion 模型在生成领域经常被说成“自监督”，因为：

- 噪声标签 ϵ 不需要人工标注，**是自己加的**
- 标签来自数据本身的变换

但从机器学习的范式上，Diffusion Policy 训练仍符合**监督学习形式**（有明确 target，有 supervised loss）。

你可以这么记：

形式上：监督学习（有标签、有回归损失）

标签来源上：自监督（标签不用人工，是模型自己构造的）

这句话非常适合写在你脑子里。

2.4 从"理解"到"执行" —— VLA 模型

模型	参数量	架构特点	适合场景
RT-2	55B	VLM直接输出动作token	大算力、高泛化
OpenVLA	7B	开源、可微调	学术研究、快速验证
Diffusion Policy	~100M	扩散生成多模态动作	精细操作、复杂轨迹

去噪生成多模态动作，甚至这个噪声在训练的时候也是这个模型自己加进去的，所以说叫这个自监督更加合适

第 4 步：实验怎么设计，才能像“论文”而不是“项目报告”

你至少要准备这些对比（审稿人最爱看）：

- **Baseline 1:** OpenVLA 直接执行（不消歧） [Kim 等 - 2024 - OpenVLA An Open...](#)
- **Baseline 2:** GroundingDINO 选 top-1 框 + 固定策略执行（不问） [Liu 等 - 2024 - Grounding DINO M...](#)
- **Baseline 3:** Diffusion Policy 直接执行（或作为动作模块） [Chi 等 - 2024 - Diffusion Policy...](#)
- **你的方法:** Ask-to-Clarify / Affordance re-rank / Multimodal prompt（选你第 1 步确定的主线）
[Lin 等 - 2025 - Ask-to-Clarify R...](#) [Ahn 等 - 2022 - Do As I Can, Not...](#)

消融（最少 3 个）：

这一步对比实验实在是太像论文了